UKF İçinde Öğrenilmiş Ölçüm Fonksiyonları: Residual ve Direct Yaklaşımlar Üzerine Kontrollü Bir Çalışma

Teknik Rapor
Kontrollü Proof-of-Concept Çalışması

***Özet*—Bu rapor, öğrenilmiş ölçüm modellerinin Unscented Kalman Filter (UKF) takip sistemi içindeki kullanımını kontrollü bir deney düzeninde inceler. Karşılaştırılan yöntemler fizik-tabanlı UKF, residual hibrit UKF (MLP/GRU ve CNN) ve direct-h öğrenilmiş ölçüm modeli kullanan UKF'dir. Çalışma, genelleme iddiası taşımayan bir proof-of-concept olarak konumlandırılmıştır. Amaç, aynı sensör mismatch ortamında, aynı veri, aynı eğitim protokolü, aynı UKF altyapısı ve aynı takip senaryosu altında yalnızca ölçüm modelinin etkisini izole etmektir. Süreç gürültüsü, doğrudan state'e eklenen soyut gürültü yerine iki boyutlu ivme dağılımı üzerinden fiziksel olarak modellenmiştir: $a_k \sim \mathcal{N}(0, \Sigma_a)$ ve $Q = G\Sigma_a G^\top$. Bu kurulum, adil karşılaştırma, residual–direct ayrımı ve zamansallık varsayımları açısından teknik bir tartışma zemini sunar.**

I. Giriş

UKF tabanlı takipte ölçüm modeli hataları, özellikle sensör kazanç/ofset sapmaları altında, filtre performansını doğrudan etkiler. Bu çalışmada amaç, öğrenilmiş ölçüm modellerinin UKF ölçüm fonksiyonuna nasıl entegre edilebildiğini ve aynı kontrollü koşullarda modelleme stratejilerinin nasıl farklılaştığını sistematik biçimde incelemektir.

Çalışmanın kapsamı bilinçli olarak sınırlıdır: tek bir kontrollü mismatch ortamı, sabit sensör geometrisi, sabit veri üretim protokolü ve tek bir trajektori üzerinde yöntemlerin karşılaştırılması hedeflenir. Bu nedenle sonuçların yorumu "genelleme" değil, "mümkünlük ve uygulanabilirlik" düzeyindedir.

II. Problem Tanımı

Takip edilen durum vektörü

$$\mathbf{x}_k = [x_k,\ y_k,\ v_{x,k},\ v_{y,k}]^\top \tag{1}$$

şeklindedir. Ölçümler, 5×5 sensörden oluşan bir grid üzerinden elde edilir ve sensör mismatch'i kazanç (g_i) ve ofset (b_i) parametreleriyle modellenir. Karşılaştırmanın temel amacı, aynı dinamik ve ölçüm verisi altında farklı ölçüm modelleme stratejilerinin UKF takip doğruluğuna etkisini incelemektir.

III. Sistem Modeli

Dinamik model sabit hız (constant-velocity) formundadır:

$$\mathbf{x}_{k+1} = F\mathbf{x}_k + G\mathbf{a}_k, \tag{2}$$

$$F = \begin{bmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}, \quad G = \begin{bmatrix} \frac{1}{2}\Delta t^2 & 0 \\ 0 & \frac{1}{2}\Delta t^2 \\ \Delta t & 0 \\ 0 & \Delta t \end{bmatrix}. \tag{3}$$

Bu yapı, ivme bozucularının konum ve hız bileşenlerine fiziksel olarak tutarlı biçimde aktarılmasını sağlar.

IV. Süreç Gürültüsü Modeli

Bu çalışmanın kritik teknik noktası, süreç gürültüsünün doğrudan state'e eklenen soyut bir terim olarak değil, ivme dağılımı üzerinden modellenmesidir:

$$\mathbf{a}_k \sim \mathcal{N}(\mathbf{0}, \Sigma_a), \tag{4}$$

$$\Sigma_a = \begin{bmatrix} \sigma_{a_x}^2 & \rho\sigma_{a_x}\sigma_{a_y} \\ \rho\sigma_{a_x}\sigma_{a_y} & \sigma_{a_y}^2 \end{bmatrix}, \tag{5}$$

$$Q = G\Sigma_a G^\top. \tag{6}$$

Klasik yaklaşımda state'e doğrudan eklenen gürültü kovaryansı çoğu kez fiziksel bir giriş mekanizmasına bağlanmaz. Burada ise gürültünün kaynağı (ivme), iletim yolu (giriş matrisi G) ve state kovaryansına yansıması (Q) açıkça ayrıştırılmıştır. Bu ayrım, model varsayımlarının yorumlanabilirliğini ve parametrelerin fiziksel anlamını güçlendirir.

V. Yöntemler

Karşılaştırılan yöntemler aşağıdaki gibidir:

1) **Fizik-tabanlı UKF**: Ölçüm fonksiyonu tamamen fizik modelinden gelir.
2) **Residual Hybrid UKF (MLP)**: Fizik tabanlı ölçüme öğrenilmiş residual düzeltme eklenir.
3) **Residual Hybrid UKF (GRU)**: Residual düzeltme GRU tabanlı ağ ile modellenir.
4) **Residual Hybrid UKF (CNN)**: Residual düzeltme CNN tabanlı ağ ile modellenir.
5) **Direct-h UKF**: Ölçüm fonksiyonu uçtan uca doğrudan öğrenilir.

A. Sunumda İzlenecek Teknik Akış

Bu çalışmanın sınıf içi veya sunum amaçlı anlatımında en anlaşılır sıra, ölçümün fiziksel olarak nasıl üretildiğini göstermekten başlayıp filtre çekirdeğine ve ardından öğrenilmiş ölçüm modellerine geçmektir. Bu nedenle anlatım dört ana blok etrafında kurulabilir: (i) fiziksel ölçüm modeli, (ii) gerçek ölçüm ile ideal fizik modeli arasındaki fark, (iii) UKF'in matematiksel çekirdeği ve (iv) aynı filtre yapısı korunurken yalnızca ölçüm fonksiyonunun değiştirilmesi.

B. Fiziksel Ölçüm Modeli

Kodun fizik tarafının temeli, `amplitude_vec_np(x_t)` fonksiyonunda tanımlanan ideal sensör modelidir. Bu fonksiyon, hedef durumu verildiğinde her sensör için beklenen ölçümü

$$a_i(\mathbf{x}) = \sqrt{\frac{P_0}{1 + d_i^2}} \tag{7}$$

ifadesiyle üretir. Burada $d_i^2 = (x_i - x)^2 + (y_i - y)^2$ sensör ile hedef arasındaki karesel uzaklıktır. Dolayısıyla hedef konumu değiştikçe sensörlerin beklenen ölçümleri sistematik biçimde değişir. Bu fonksiyon olmadan modelin fiziksel referans noktası ortadan kalkar; residual veya direct yaklaşımların neyi düzelttiği ya da neyi öğrendiği açık biçimde tanımlanamaz.

C. Gerçek Ölçüm ile Fizik Modeli Arasındaki Fark

Kodun motivasyonu, ideal fizik modeli ile gerçek ölçüm üretim süreci arasındaki boşlukta ortaya çıkar. `make_true_sensor_params`, `shadowing_term_np`, `true_measurement_np` ve `sample_measurement_np` fonksiyonları bu farkı açık biçimde kurar. İdeal model yalnızca uzaklığa bağlı beklenen genliği tanımlarken, gerçek ölçümde sensör kazanç hataları, ofset sapmaları, konuma bağlı shadowing etkisi ve ek ölçüm gürültüsü birlikte yer alır. Başka bir deyişle, öğrenilmiş bileşen fizik modelinin yerine geçmek için değil, fizik modelinin açıklayamadığı sistematik farkı yakalamak için devreye sokulmaktadır.

Residual yaklaşımda ölçüm modeli

$$\hat{h}(\mathbf{x}) = h_{\text{phys}}(\mathbf{x}) + r_\theta(\mathbf{x}) \tag{8}$$

şeklindedir. Direct yaklaşımda ise

$$\hat{h}(\mathbf{x}) = h_\theta(\mathbf{x}) \tag{9}$$

olup fizik model zorunlu bir bileşen olarak kullanılmaz.

D. MLP, GRU ve CNN Tabanlı Residual Modeller

Residual ölçüm modeli, her sensör için

$$\phi_i = [a_i, d_i^2, x, y, v_x, v_y, x_i, y_i] \in \mathbb{R}^8 \tag{10}$$

özellik vektörünü kullanır ve residual çıktıyı üretir. Kod düzeyinde tüm mimariler aynı fiziksel girdiyi paylaşır; fark, yalnızca öğrenme mimarisindedir.

Tablo I
RESIDUAL AI MODELLERI ICIN KATMAN OZETLERI.

Model	Katman yapisi
MLP	Linear(8,128)-ReLU-Linear(128,128)-ReLU-Linear(128,1)
GRU	GRU(input=8, hidden=128, layers=1)-Linear(128,1)
CNN	Conv2D(8,64,3x3)-ReLU-Conv2D(64,64,3x3)-ReLU-Conv2D(64,1,1x1)

1) MLP tabanlı residual model (ResidualPerSensorMLP): MLP, sensör başına özellikleri tam bağlı katmanlar ile işler:

$$\mathbb{R}^8 \xrightarrow{\text{Linear+ReLU}} \mathbb{R}^{128} \xrightarrow{\text{Linear+ReLU}} \mathbb{R}^{128} \xrightarrow{\text{Linear}} \mathbb{R}^1. \tag{11}$$

Ağırlıklar sensörler arasında paylaşılır; böylece model, her sensör konumu için aynı fonksiyon ailesini uygular ve parametre verimliliği sağlar.

2) GRU tabanlı residual model (ResidualPerSensorGRU): GRU modelinde sensör indeksi bir dizi olarak ele alınır. Katman yapısı:

$$\text{GRU}(\text{input} = 8,\ \text{hidden} = 128,\ \text{layers} = 1) \to \text{Linear}(128 \to 1). \tag{12}$$

Bu yapı, sensör sırası boyunca gizli durum taşıyarak komşu sensör örüntülerini zamansal-analojik biçimde modelleyebilir.

3) CNN tabanlı residual model (ResidualGridCNN): CNN modeli, sensörleri 5×5 grid olarak işler. Kanal sayısı 8'dir. Katmanlar:

$$\text{Conv2D}(8 \to 64, k = 3, p = 1) + \text{ReLU} \tag{13}$$

$$\text{Conv2D}(64 \to 64, k = 3, p = 1) + \text{ReLU} \tag{14}$$

$$\text{Conv2D}(64 \to 1, k = 1). \tag{15}$$

3×3 evrişim çekirdekleri yerel uzamsal korelasyonları yakalar; 1×1 son katman sensör başına residual haritası üretir. Bu yaklaşım, sensörlerin 2B grid yerleşimini doğrudan kullanarak uzamsal yapının (sensor grid spatial structure) öğrenme sürecinde etkin biçimde değerlendirilmesini sağlar.

Mimariler arası teknik ayrım: MLP global doğrusal olmayan eşlemeyi, GRU sensör sırası boyunca bağımlılık modellemeyi, CNN ise 2B sensör uzayındaki yerel yapıyı öne çıkarır. Bu ayrım, aynı UKF altyapısı altında mimari etkisinin izole edilmesini sağlar.

VI. VERI ÜRETIMI VE KARŞILAŞTIRMA PROTOKOLÜ

Adil karşılaştırma için tüm yöntemler aşağıdaki ortak kurallarla değerlendirilmiştir:

- Aynı sensör yerleşimi: $5 \times 5 = 25$ sensör, koordinatlar $[-30, 30]$ aralığında.
- Aynı mismatch parametreleri: gerçek g_i ve b_i tek sefer üretilir, tüm deney boyunca sabit tutulur.
- Aynı veri üretim süreci: eğitim/doğrulama kümeleri aynı çekirdek ayarlarıyla üretilir.
- Aynı train/validation bölünmesi: tüm modeller için ortak bölünme kullanılır.

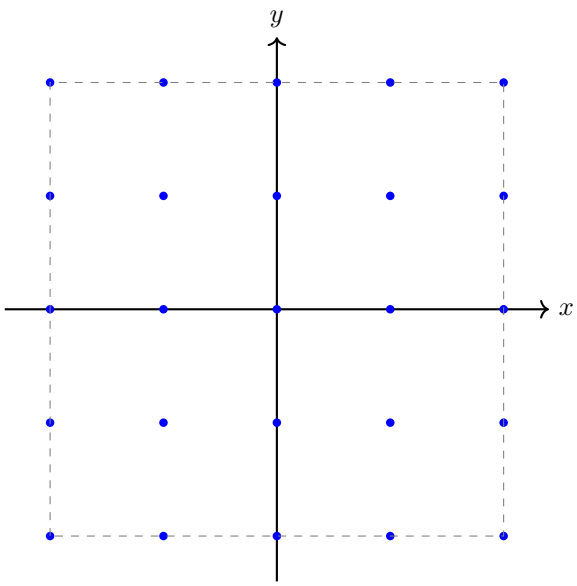

Şekil 1. Deneylerde kullanılan 5×5 sensör yerleşimi. Sensör koordinatları her iki eksende $[-30, 30]$ aralığında eşit aralıklıdır.

- Aynı eğitim koşulları: epoch, batch ve öğrenme oranı eşitlenir.
- Aynı UKF altyapısı: filtre implementasyonu ve Q/R ayarları yöntemler arasında değiştirilmez.
- Aynı test girdileri: aynı trajektori ve aynı ölçümlerle test yapılır.

Bu protokol, karşılaştırma değişkenini "yalnızca ölçüm modeli" ile sınırlar; böylece ablation-style bir deney tasarımı elde edilir.

VII. Eğitim Ayarları

Öğrenilmiş bileşenler için ortak eğitim ayarları aşağıdaki gibidir:

- Eğitim örnek sayısı: $N_{\text{train}} = 30000$
- Doğrulama örnek sayısı: $N_{\text{val}} = 8000$
- Epoch sayısı: 200
- Batch size: 512
- Öğrenme oranı: 3×10^{-4}

Bu sabitleme, mimari karşılaştırmasında optimizasyon koşullarından kaynaklı sapmayı azaltmayı amaçlar.

VIII. Deney Tasarımı

Takip senaryosu aşağıdaki parametrelerle tanımlanır:

- Zaman adımı: $\Delta t = 0.25$
- Toplam adım: $T = 80$
- Gerçek ve tahmini başlangıç durumları farklıdır ($\mathbf{x}_0^{\text{true}} \neq \mathbf{x}_0^{\text{est}}$).
- Başlangıç kovaryansı tanımlıdır: $P_0 = \text{diag}(4, 4, 1, 1)$.
- Süreç gürültüsü parametreleri: $\sigma_{a_x} = 0.20$, $\sigma_{a_y} = 0.20$, $\rho = 0.15$.

Başlangıçta bilinçli sapma verilmesi, filtre yakınsamasının yalnızca ideal başlangıç koşuluna bağlı kalmamasını sağlar.

A. UKF'nin Bayesçi Çalışma Prensibi

UKF, doğrusal olmayan durum-uzayı modelinde ardışık Bayes güncellemesi uygular. Her adımda hedef, posterior dağılımı

$$p(\mathbf{x}_k \mid \mathbf{z}_{1:k}) \tag{16}$$

olasılık yoğunluğu ile temsil etmektir. UKF bu dağılımı Gauss yaklaşımıyla $(\hat{\mathbf{x}}_k, P_k)$ çiftine indirger.

Zaman güncellemesi (prediction):

$$p(\mathbf{x}_k \mid \mathbf{z}_{1:k-1}) = \int p(\mathbf{x}_k \mid \mathbf{x}_{k-1}) p(\mathbf{x}_{k-1} \mid \mathbf{z}_{1:k-1}) d\mathbf{x}_{k-1}. \tag{17}$$

UKF bu integrali sigma noktaları ile yaklaşıklar. Merwe sigma noktaları,

$$\chi_{k-1}^{(i)} = \hat{\mathbf{x}}_{k-1} \pm \sqrt{(n+\lambda)P_{k-1}} \tag{18}$$

biçiminde seçilir ve dinamik modelden geçirilir.

Ölçüm güncellemesi (correction): Öngörülen sigma noktaları ölçüm uzayına taşınır, yenilik kovaryansı S_k ve çapraz kovaryans $P_{xz,k}$ hesaplanır:

$$K_k = P_{xz,k} S_k^{-1}, \tag{19}$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + K_k(\mathbf{z}_k - \hat{\mathbf{z}}_k), \tag{20}$$

$$P_k = P_k^- - K_k S_k K_k^\top. \tag{21}$$

Bu işlem, prior belirsizliği ile ölçüm bilgisini olasılıksal olarak birleştirir; dolayısıyla UKF'nin temel karakteri Bayesçidir.

Bu çalışmada UKF tercih edilmesinin temel nedeni, ölçüm fonksiyonunun öğrenilmiş modellerle tanımlanmasıdır. Öğrenilmiş ölçüm modelleri genellikle kapalı form türev ifadeleri vermez ve yüksek derecede doğrusal olmayan davranış sergiler. EKF yaklaşımında gerekli Jacobian hesabı bu durumda ya hesaplama maliyetini artırır ya da sayısal kararlılığı zayıflatabilir. UKF ise türev gerektirmeden sigma noktaları üzerinden yayılım yaptığı için, residual ve direct-h gibi öğrenilmiş ölçüm modellerinin filtreye entegrasyonunu daha kararlı ve doğal bir çerçevede sağlar. Kritik nokta, ölçüm modelinin black-box olarak kullanılabilmesidir: UKF, ölçüm fonksiyonunu differentiable olma zorunluluğuna bağlamaz.

Bu çalışmadaki Bayesçi entegrasyonun anlamı: Fizik-tabanlı, residual ve direct-h ölçüm modelleri yalnızca $h(\cdot)$ fonksiyonunu değiştirir. Bayes güncelleme yapısı, sigma noktası üretimi ve kovaryans güncellemesi aynı kalır. Böylece öğrenilmiş bileşen, filtre mimarisini değil ölçüm olasılık modelini değiştirerek posterior kestirimi etkiler.

B. UKF'in Kalbi

Teknik açıdan bakıldığında filtrenin matematiksel omurgası `MerweSigmaPoints`, `unscented_transform`, `UKF.predict()` ve `UKF.update()` bloklarında yer alır. Sunum sırasında bu yapı şu sırayla anlatılabilir: önce sigma noktaları üretilir, ardından bu noktalar dinamik model üzerinden ileri taşınır, daha sonra ölçüm uzayına projekte edilir, bu görüntülerden ortalama ve kovaryans

hesaplanır ve son olarak Kalman kazancı kullanılarak posterior durum düzeltilir. Başka bir deyişle filtre akışı "sigma point üret – dinamikten geçir – ölçüm uzayına taşı – ortalama ve kovaryans hesapla – Kalman kazancıyla düzelt" şeklinde özetlenebilir. Bu nedenle kodun en kritik matematiksel yapısı doğrudan bu blokta toplanmaktadır.

IX. Değerlendirme Metodolojisi

Ana metrik pozisyon RMSE'dir:

$$\mathrm{RMSE}_{\mathrm{pos}} = \sqrt{\frac{1}{T}\sum_{k=1}^{T} \|\hat{\mathbf{p}}_k - \mathbf{p}_k\|_2^2}, \tag{22}$$

burada $\mathbf{p}_k = [x_k, y_k]^\top$.

Ek değerlendirmeler:

- Zaman boyunca anlık pozisyon hatası $\|\hat{\mathbf{p}}_k - \mathbf{p}_k\|_2$.
- Tahmin ve gerçek trajektori üst üste çizimleri.

Sayısal RMSE değerleri bu metinde verilmediğinden, sonuçlar metodolojik çerçeve üzerinden tartışılmaktadır.

X. Sonuçlar ve Teknik Tartışma

A. Adil karşılaştırmanın teknik gerekliliği

Farklı veri kümeleri, farklı mismatch parametreleri veya farklı UKF ayarları ile yapılan karşılaştırmalar, model etkisini izole edemez. Bu çalışmada tüm paylaşılan bileşenlerin sabitlenmesi, sonuç farklarının ölçüm modelinden kaynaklandığı yorumunu teknik olarak savunulabilir hale getirir.

B. Residual ve Direct yaklaşımının yapısal farkı

Residual yaklaşım, fizik modelin sağladığı ön-bilgiyi korur ve yalnızca sistematik ölçüm hatalarını düzeltir. Bu, veri verimliliği ve kararlılık açısından avantaj sağlayabilir. Direct-h yaklaşımı ise daha esnek olmasına karşın, fizik modelden bağımsız öğrenme nedeniyle yanlış genelleme veya filtre tutarlılığı kaybı riski taşır. Özellikle veri kapsamı sınırlıysa direct modelin güvenilirliği dikkatle incelenmelidir.

C. Residual ve Direct-h Farkının Kod Düzeyi Açıklaması

Kod yapısında iki yaklaşımın ayrımı ölçüm fonksiyonunun nasıl kurulduğunda ortaya çıkar. Residual yaklaşımda UKF içindeki ölçüm modeli

$$\hat{z}(x) = h_{\mathrm{phys}}(x) + r_\theta(\phi) \tag{23}$$

şeklindedir; yani fizik tabanlı genlik modeli korunur ve öğrenilen ağ yalnızca düzeltme terimi üretir. Direct-h yaklaşımda ise

$$\hat{z}(x) = h_\theta(\phi) \tag{24}$$

olarak ölçüm fonksiyonu bütünüyle ağ tarafından temsil edilir.

Bu bölümün sunumdaki en güçlü mesajı şudur: filtre yapısı aynı kalırken yalnızca ölçüm fonksiyonu değişmektedir. Kod düzeyinde bu durum, `hx_meas_physics_only(x)` ile yalnızca fizik modelinin, `hx_meas_hybrid(x, net, device)` ile fizik + residual düzeltmenin ve `hx_meas_direct(x, net, device)` ile tamamen öğrenilmiş ölçüm modelinin kullanılmasıyla açıkça görülür. Dolayısıyla projenin temel fikri, filtreyi değiştirmek değil, ölçüm modelini daha güçlü hale getirmektir.

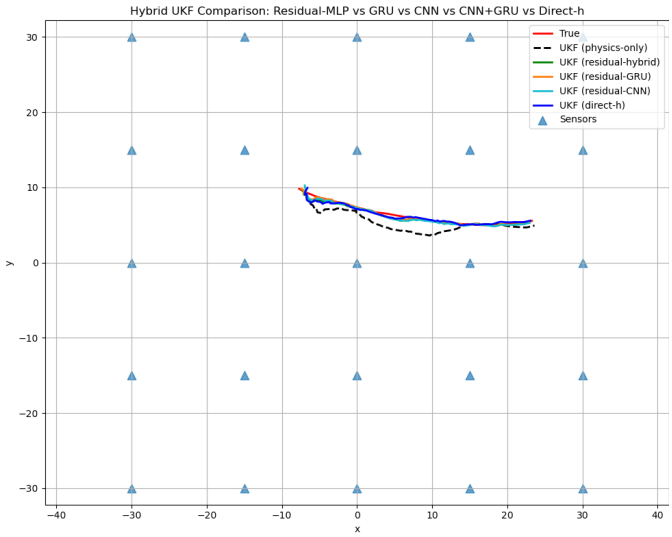

Şekil 2. Takip karşılaştırması: gerçek trajektori ile algoritma çıktılarının uzaysal kıyası.

Bu nedenle residual model, fiziksel ön-bilgiyi filtreye doğrudan taşırken; direct-h model, aynı görevi tamamen veriyle öğrenir. Yüklenen deney çıktılarında performans sıralaması açık biçimde GRU tabanlı residual model > MLP tabanlı residual model > CNN tabanlı residual model > direct-h model şeklindedir. Buna göre en düşük hata GRU yaklaşımında gözlenmiş, direct-h ise karşılaştırılan yöntemler içinde en düşük takip doğruluğunu vermiştir.

D. Deney Çıktılarının Entegrasyonu

Aşağıdaki görseller, performansı genel davranıştan istatistiksel özete doğru sıralı biçimde sunar. Şekil 2 incelendiğinde GRU tabanlı yaklaşımın gerçek trajektoriye daha yakın bir iz sürdüğü, direct-h yaklaşımının ise özellikle dönüş ve ivmelenme bölgelerinde daha belirgin sapma ürettiği görülmektedir. Şekil 3, bu farkın zamana dağılımını açıklar: GRU eğrisi daha düşük ve daha dengeli bir hata profili sergilerken, direct-h eğrisi daha yüksek genlikli dalgalanma göstermektedir. Şekil 4 ve Şekil 5 üzerindeki Monte Carlo özetleri, tek koşu gözlemlerini istatistiksel olarak desteklemekte; ortalama hata düzeyinde sıralamanın GRU > MLP > CNN > direct-h şeklinde korunduğunu göstermektedir.

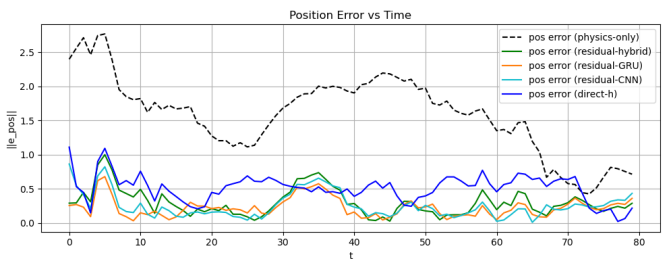

Şekil 3. Zaman boyunca pozisyon farkı: algoritmaların gerçek değerden sapma profili.

Şekil 4. 100 tekrar üzerinden Monte Carlo MSE özeti.

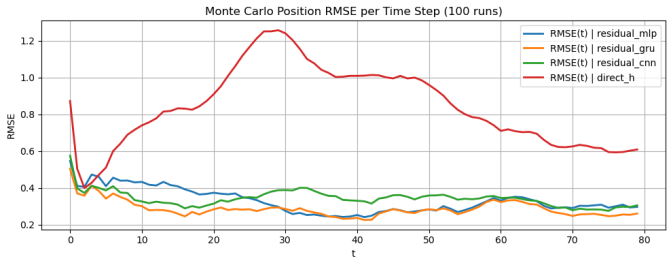

Şekil 5. 100 tekrar üzerinden Monte Carlo RMSE özeti.

E. GRU ve zamansal bağımlılık sorusu

Bu problem tanımında ölçüm fonksiyonu ağırlıklı olarak state→measurement eşlemesi niteliğindedir. Bu nedenle güçlü zamansal bellek (GRU) her durumda zorunlu avantaj üretmeyebilir. Eğer mismatch dinamik ve zamana bağlı olsaydı, rekürent yapıların katkısı daha belirgin olurdu. Bununla birlikte bu çalışmada GRU'nun en iyi sonucu vermesi, sensörler arası uzamsal korelasyonun sensör dizilimi boyunca bir sıra yapısı gibi temsil edilmesinden kaynaklanıyor olabilir. Bu nedenle elde edilen üstünlük, zamansallıktan çok sequence benzeri korelasyon modelleme etkisiyle açıklanmaktadır.

F. Fiziksel süreç gürültüsü modelinin etkisi

$Q = G\Sigma_a G^\top$ formülasyonu, süreç gürültüsünü kinematik yapıyla tutarlı hale getirir. Böylece konum/hız kovaryans bileşenleri ivme belirsizliğinden türetilir ve parametre seçimi daha yorumlanabilir olur. Klasik "state'e doğrudan gürültü" yaklaşımı pratik olsa da, gürültü kaynağı ve state bileşenleri arasındaki fiziksel bağ daha zayıf kalır.

XI. Sonuç

Bu çalışma, öğrenilmiş ölçüm modellerinin UKF içine entegrasyonu için sistematik bir değerlendirme çerçevesi sunmuştur. Tasarımın ana gücü, tüm yöntemlerin aynı veri, aynı mismatch, aynı senaryo ve aynı filtre altyapısı altında karşılaştırılmasıdır. Bu yapı sayesinde ölçüm modelinin etkisi açık biçimde izole edilmiş ve yöntemler arası teknik farkların adil biçimde analiz edilmesi sağlanmıştır.